

Implementasi Deep Learning untuk Klasifikasi Motor Imagery pada Sinyal EEG

Sitasi artikel

Agastya, I. M. A., Marco, R., & Puspitasari, N. F. (2024). Implementasi Deep Learning untuk Klasifikasi Motor Imagery pada Sinyal EEG. JOINTECS (Journal of Information Technology and Computer Science)

Latar & Tujuan

Motor imagery (MI) pada EEG merupakan modalitas penting dalam sistem Brain-Computer Interface (BCI), tetapi pengolahan sinyal EEG untuk mengenali pola MI sangat menantang karena sifat sinyal yang kompleks dan variabilitas antar subjek. Penelitian ini bertujuan membandingkan kinerja empat arsitektur deep learning—yaitu EEGNet, EEGConformer, EEGInception, dan EEGITNet—dalam klasifikasi data EEG pada konteks motor imagery untuk menentukan model yang paling efektif.

Metode

Data / Alat: Dataset EEG dikumpulkan dari 9 partisipan sehat, dengan 22 saluran EEG + 3 saluran EOG, sampling rate 250 Hz, dan filter bandpass 0,5–100 Hz serta notch filtering. Data disimpan dalam format GDF.

Hardware & library: Pelatihan menggunakan GPU Titan V (12 GB) dan CPU Intel generasi ke-9, serta perangkat lunak seperti PyTorch, braindecode, moabb, skorch, dan library lainnya.

Evaluasi: Kinerja masing-masing arsitektur dievaluasi berdasarkan akurasi rata-rata dan stabilitas (deviasi antar subjek).

Hasil / Temuan kunci

Akurasi rata-rata:

EEGConformer: ~ 72,41 %

EEGNet: ~ 71,88 %

EEGInception: ~ 55,59 %

EEGITNet: (lebih rendah dan variatif, tidak disebutkan angka rata-rata secara konsisten)

EEGConformer dan EEGNet menunjukkan performa paling kompetitif dan stabil antar subjek, sedangkan EEGInception paling lemah dan sangat fluktuatif

Terdapat variabilitas antar subjek yang cukup signifikan, menunjukkan bahwa model yang sama bisa berkinerja berbeda tergantung karakteristik subjek.

Kontribusi & Keterbatasan

Kontribusi baru:

Perbandingan empiris langsung dari empat arsitektur deep learning (yang sudah populer atau relatif baru) dalam tugas klasifikasi motor imagery EEG dalam konteks data lokal. Menunjukkan bahwa arsitektur sederhana seperti EEGNet tetap kompetitif dan, dalam beberapa kasus, hampir menyamai arsitektur yang lebih kompleks seperti EEGConformer. Menyoroti pentingnya adaptasi per-subjek atau pendekatan personalisasi dalam tugas klasifikasi EEG.

Keterbatasan:

Ukuran sampel relatif kecil (9 partisipan), sehingga generalisasi ke populasi lebih luas terbatas. Belum dieksplorasi strategi adaptasi domain atau transfer learning antar sesi/subjek. Tidak ada analisis mendalam terhadap pengaruh parameter arsitektur (misalnya jumlah lapisan, kerangka waktu) terhadap performa. Performansi pada arsitektur lain (EEGITNet) kurang konsisten dan belum dieksplorasi secara optimal.

Takeaway

Dalam pengembangan sistem klasifikasi motor imagery EEG untuk aplikasi praktis (misalnya BCI), memilih arsitektur yang relatif ringan dan stabil seperti EEGNet atau EEGConformer bisa lebih andal dibandingkan arsitektur kompleks jika data terbatas; dan selalu mempertimbangkan adaptasi atau kalibrasi khusus subjek agar performa konsisten.